VIRTUAL METROLOGY × MACHINE LEARNING

重ね合わせ制御における仮想計測と機械学習

具体事例・主要手法・運用上のポイント

SK hynix × ASML ／ KLA ／ SPIE / EMLC 論文・USPTO 実装事例から



2026 年 6 月 ｜ 社内技術リファレンス

© 2026 Internal Technical Note

01

アジェンダ

本資料の流れ

1 **Virtual Metrology (VM) とは**
目的・データソース

2 **なぜ必要か**
計測の物理限界 / コスト / カバレッジ

3 **具体事例 ①**
SK hynix × ASML (SPIE 9424, 2015)

4 **具体事例 ②**
ASML EMLC2018 — NN による Overlay 予測

5 **具体事例 ③**
KLA — Optical Inspection × ML 推定

6 **主要 ML 手法の比較**
GBM / DNN / GP / kNN / Random Forest

7 **Feature Engineering**
3 カテゴリの特徴量設計

8 **Physics × ML ハイブリッド**
Zernike / Grid モデルとの結合

9 **ドリフト検知と再学習**
MLOps 観点の運用

10 **運用ベストプラクティス**
現場の 8 原則

11 **アンチパターン**
失敗事例から学ぶ

12 **まとめと展望**
Hybrid AI Metrology へ

© 2026 Internal Technical Note

02

Virtual Metrology (VM) とは

物理計測なしに「測ったことにする」推定技術

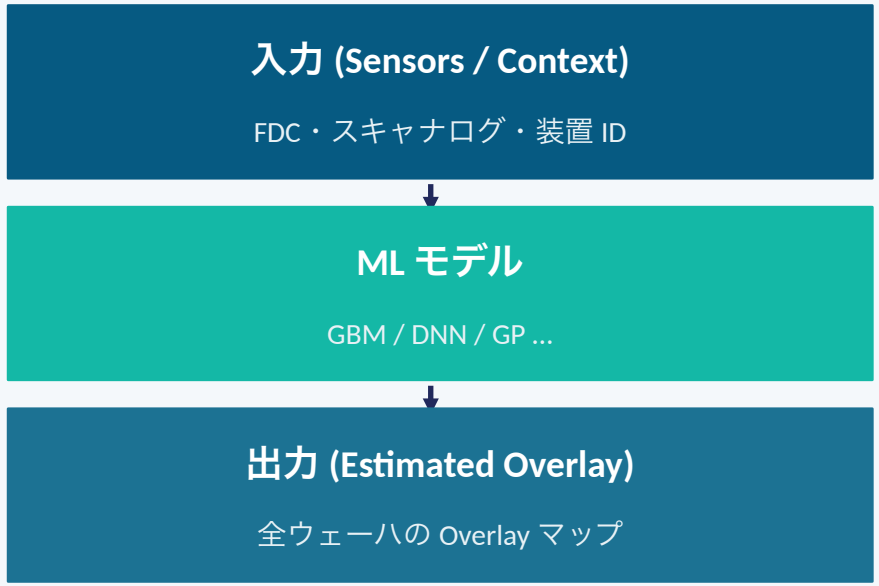
定義

プロセスやスキャナの稼働データから、ウェーハの品質指標（ここでは Overlay）を計測せずに推定する技術。本来オフラインで測るべき指標を、装置センサ / FDC / Context データから ML で予測する。

Overlay VM の典型タスク

- ロット中の数枚から、全ウェーハの Overlay マップを推定
- 露光前にスキャナログから当該ロットの Overlay 残差を予測
- 異常ロットを早期特定し、抜き取り検査へ誘導
- Feedforward 制御へ予測値を流し込み、補正残差を低減

VM の基本フロー



従来「ウェーハの 3〜5 % を計測」だった枠を、推定で 100 % カバーする。

© 2026 Internal Technical Note

02

なぜ Overlay に VM が必要か

「全部測る」「リアルタイムに測る」が物理的に難しい

≈ 5 %

計測カバレッジ

高生産ラインで実測される Overlay の典型割合。残り 95 % は装置の挙動から「推測」するしかない。

数 日

計測遅延

オフライン計測サイクルが長く、R2R 補正が後手に回る。VM があれば数時間スケールへ短縮 (KLA 試算)。

$R^2 \approx 0.80$

ASML EMLC 2018 の予測性能

Non-correctable Overlay 成分について、NN ベース VM で達成された予測精度。

VM の役割は「物理計測の代替」ではなく「物理計測を疎にしても安全」にすること。ML 予測 + 物理計測の二刀流が大前提。

© 2026 Internal Technical Note

具体事例 ① — SK hynix × ASML (SPIE 9424, 2015)

「インライン計測+ 機械学習」によるバーチャル Overlay

論文タイトル

Virtual overlay metrology for fault detection supported with integrated metrology and machine learning (SPIE 9424, 2015)

研究の枠組み

- SK hynix **のインライン計測装置に** NN **ベースの** VM **を組み込み**
- **スキャナの既知の寄与因子（ステージ、レンズ、レチクル等）を学習**
- **露光した全ウェーハの** Overlay **ベクトルマップを近似する関数を獲得**
- **標準集団から外れた** Overlay **シグネチャを持つロットを**

オフライン計測へ自動誘導 (Excursion validation)

運用フロー

1. **ロット内 3〜5 枚を物理計測**
   サンプリング計測で base を取る
2. **NN モデルで全ウェーハを推定**
   Trained function により Overlay マップを近似
3. **シグネチャの分布をモニタ**
   標準集団との Mahalanobis 距離を計算
4. **外れ値ロットを抽出**
   Excursion 候補を自動フラグ
5. **オフライン計測で検証**
   ML 予測の信頼性を物理で押さえる

出典: Lee et al., SPIE 9424 (2015) / USPTO 10,964,566 ML on Overlay Virtual Metrology

© 2026 Internal Technical Note

具体事例 ② — ASML EMLC 2018

NN による Overlay 予測 ／ Fab Cycle Time 削減を狙った量産前提の VM

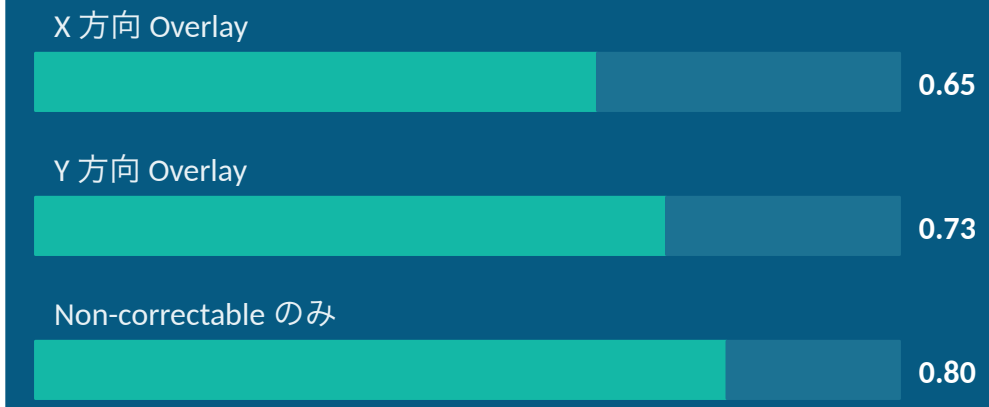
モデル：3 カテゴリの特徴量を入力する NN ベース VM

1 履歴 Overlay
直前 Implant 層の計測値
(下層シグネチャ)

2 Tool Fingerprint
スキャナ + 各 Chuck の
固有寄与パターン

3 Context + APC
Tool/Reticle/Process ID
適用された APC 補正値

性能（R^2 値）



学び（Take-aways）

- Correctable は物理モデルで吸収済 → ML は Non-correctable の説明に集中
- 3 カテゴリの特徴量を分離して持つことが性能のキモ
- Chuck 別 fingerprint を入れないと精度が頭打ちになる
- MATLAB / Python の物理モデルと ML を共通プラットフォームで扱う

出典: Hasibi et al., EMLC 2018 / MathWorks ユーザーストーリー (ASML)

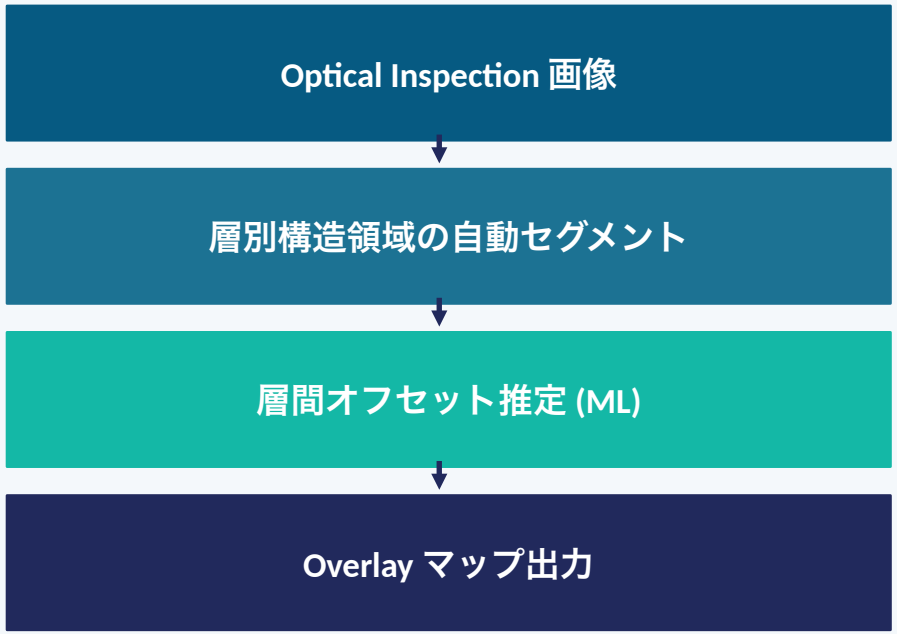
© 2026 Internal Technical Note

03

具体事例 ③ — KLA Optical Inspection × ML

USPTO 12,535,744 — 光学検査画像から Overlay を推定

推定パイプライン



特徴

Overlay 専用ターゲットに依存しない
通常の光学検査画像から直接、層間ずれを推定。Overlay 計測点を増設せずに密なマップが得られる

層ごとに別 ML モデル
プロセス層が異なる構造の特徴ごとに、専用モデルを訓練。誤推定をスタックの影響から守る

スループットを犠牲にしない
既存検査の通り抜けデータで Overlay 情報を抽出 = サイクルタイム増えない

異常検知と連動
予測 Overlay が異常分布のとき、検査装置内で自動的に追加サンプリングを発動

出典: USPTO 12,535,744『Overlay estimation based on optical inspection and machine learning』(KLA)

© 2026 Internal Technical Note

04

主要 ML 手法の比較 — Overlay VM 文脈

実装の重さと特性で使い分ける

手法	強み	弱み	Overlay VM での出番
Gradient Boosting (XGBoost / LightGBM)	表形式特徴量に強い／少量データでも安定	外挿に弱い／空間構造を直接扱えない	Lot 単位の集約特徴量から予測する標準ベースライン
ニューラルネット (DNN / MLP)	非線形・高次の相互作用に強い	学習データ量と特徴設計に敏感	ASML EMLC 2018 で採用。Non-correctable の予測
畳み込み NN (CNN)	空間マップを直接入力できる	前処理 (リサンプル) が必要	Overlay マップ画像や検査画像からの直接推定
Gaussian Process (GP)	予測値に不確実性を付与できる	計算量がデータ点数の 3 乗で増加	信頼区間を R2R に渡す Critical 層向け
Random Forest / kNN	実装が容易・解釈しやすい	高次元で性能頭打ち	プロトタイプ／ルールベース置換／フォールバック
Hybrid (Physics + ML)	物理モデルを Prior にして外挿に強い	実装コストが高い	Zernike / Grid モデル残差を ML で説明する本命構成

どれか 1 つで完結する必要はない。ベースライン (GBM) → 本命 (NN / Hybrid) → 安全網 (Rule) の 3 階層で構築する。

© 2026 Internal Technical Note

Feature Engineering — 特徴量の 3 カテゴリ

ASML / KLA 系論文で共通して採用されている設計

① 履歴 Overlay

Layer history

- 直前 Implant 層の Overlay 計測値
- 下層のグリッドシグネチャ
- Mahalanobis 距離での外れ度
- 前ロットの残差 (時系列ラグ)

② 装置 Fingerprint

Tool / Chuck signature

- スキャナ ID 別の固有寄与
- Chuck 1 / Chuck 2 の差分
- ステージ非線形成分
- レンズ収差 (Zernike) ログ

③ Context + APC

Recipe / Correction

- Tool / Reticle / Process ID
- 適用された APC 補正値
- メンテからの経過時間
- 温度・湿度・Wafer 順序

Tips：3 カテゴリを「同じテーブルに混ぜる」のではなく、グループ別の Embedding / 別ネットワーク枝に分けると Robust になる。

© 2026 Internal Technical Note

04

Physics × ML ハイブリッド構成

物理モデルの「説明できる部分」と ML の「説明できない部分」を分担

構成のイメージ

Overlay (実測) = 物理モデル + 残差 (ML)

物理モデル	残差 ML
Grid (Lin/HO) Zernike Stage Distortion	GBM / DNN / GP Context + APC Drift 成分

物理が「説明できる部分」を先に引き、残った成分だけを ML に渡す。

→ 学習データを節約／外挿に強い／解釈性が確保しやすい

なぜハイブリッドが事実上の本命か

- Pure ML は外挿で大きく外す。新しい装置・新ロットで安全マージンが取れない。
- 物理モデルだけでは残った 20〜30 % の Non-correctable を説明できない (EMLC 2018)。
- 残差だけを ML に渡せば、特徴量が一桁少なくて済み、過学習しにくい。
- 解釈性：物理項は物理量で説明可能。ML 項は補助という位置づけにできる。
- プロセス変更時に物理パラメータだけ差し替えれば、ML をフル再学習せずに済むケースも多い。

© 2026 Internal Technical Note

05

ドリフト検知と再学習 — MLOps 視点

VM を「動かし続ける」ためのループ

運用ループ

1. **予測** — VM が Overlay を推定
2. **観測** — サンプリング物理計測
3. **残差監視** — 予測 vs 実測の誤差分布
4. **ドリフト判定** — 閾値超 / KS / PSI
5. **再学習トリガ** — 新データで学習更新

ドリフト検知の典型シグナル

- 予測 Overlay と実測の Bias が長期トレンドで増加
- Population Stability Index (PSI) > 0.2 のロット連続発生
- Context (Tool / Reticle) の構成変化
- 信頼区間 (GP の σ) の異常拡大

再学習トリガーの設計

- 定期トリガー (例: 週次) + イベントトリガー (大規模メンテ後)
- Context Key が新規追加 (新装置 / 新レチクル) は即時再学習
- 再学習後の精度が劣化していたら自動ロールバック
- Shadow Deploy で本番並走 → 一定期間 OK で切替

© 2026 Internal Technical Note

05

運用ベストプラクティス 8 原則

VM をプロダクションに乗せる際の現場知

01 **物理計測を捨てない**
VM は「疎にする」もので「無くす」ものではない

02 **Context Key を必ず分離**
Tool / Reticle / Process / Chuck で別系列を持つ

03 **信頼度を出力する**
予測値だけでなく σ や PSI を一緒に R2R に渡す

04 **新規 Context は予測しない**
未学習の組合せはルールベースのフォールバックへ

05 **残差監視を常設**
予測 vs 実測の差を Bias / Variance に分けて見る

06 **Shadow Deploy**
再学習モデルは即本番化せず並走で評価

07 **物理モデルを Prior に**
Pure ML より Hybrid を選ぶ。外挿に効く

08 **再学習をスケジュール化**
週次 / イベント / 性能劣化の 3 系統で発火

© 2026 Internal Technical Note

05

アンチパターン — よくある失敗

「動いて見えるけど壊れている VM」のパターン

全特徴量を 1 つのテーブルに混ぜる

Context が変わると一気に劣化。Embedding / 別枝に分けるべき。

Pure ML のみで運用

新装置・新レチクルで予測が外れる。物理モデルを Prior に。

信頼度を捨てて点推定だけ流す

R2R が VM の自信を区別できず、ノイズに過剰反応する。

再学習をマニュアル運用

属人化し、いつドリフトしたか追えなくなる。スケジュール化必須。

物理計測を「無駄」と削減

VM の正しさを誰も確認できない。物理計測は Ground Truth の砦。

Shadow Deploy なしで本番置換

再学習後にむしろ劣化するケースあり。並走 → 切替が原則。

© 2026 Internal Technical Note

06

事例マッピング — どの場面でどれが効くか

目的と手法の対応関係を一覧化

事例 / 出典	目的	主な手法	効果
SK hynix × ASML (SPIE 9424, 2015)	全ウェーハの Overlay 推定 + Excursion 検知	NN による関数近似 + 異常検知	サンプリング計測から全数推定／異常ロット早期発見
ASML EMLC 2018	Fab Cycle Time 削減 / Overlay 予測	NN + 3 カテゴリ特徴量	R^2 0.65 (X) / 0.73 (Y) / 0.80 (Non-correctable)
KLA USPTO 12,535,744	光学検査画像から Overlay 推定	層別 ML / セグメント + 回帰	Overlay 専用ターゲット不要／密なマップ
ASML USPTO 10,964,566	Overlay VM の汎用フレーム	NN ベース + Context 分離	Implant / Scanner / APC を分けて扱う設計
KLA Archer + AI	計測マークの品質判定 / フィルタ	画像分類 + 異常検知	計測 S/N を保ち、補正の根拠を堅くする
Hybrid (社内実装例)	Non-correctable の残差説明	Zernike + GBM ハイブリッド	学習データを節約しつつ外挿性を確保

どの事例も「物理計測を残す」「Context を分ける」「Hybrid 化する」の 3 点は共通している。

まとめと展望

Hybrid AI Metrology へ

- VM は「物理計測を疎に運用しつつ全数推定する」ための運用技術。物理計測を残すことが前提。
- 公開された具体事例（SK hynix × ASML、ASML EMLC 2018、KLA USPTO）は、いずれも 3 カテゴリ特徴量 + NN/Hybrid の構成を取る。
- Non-correctable Overlay の説明 ($R^2 \approx 0.80$) が ML 単独で達成された一方、Correctable は物理側で吸収するのが正攻法。
- MLOps 観点：ドリフト検知・再学習トリガー・Shadow Deploy をはじめから設計に組み込む。
- 今後は Hybrid (Zernike + ML)、Multi-Tool 横断 VM、Confidence-aware R2R が主戦場になる。

ご清聴ありがとうございました